Documentación de la base de datos

a) Nombre de la base de datos

National Health and Nutrition Health Survey 2013-2014 (NHANES) Age Prediction Subset

b) Fuente (URL)

Repositorio: **UCI Machine Learning Repository**
Institución: University of California, Irvine

Referencia completa:

Dua, D. & Graff, C. (2019). *UCI Machine Learning Repository*. Irvine, CA: University of California, School of Information and Computer Science.

Dataset específico:

National Health and Nutrition Health Survey 2013-2014 (NHANES) Age Prediction Subset
Disponible en:
https://archive.ics.uci.edu/dataset/887/national+health+and+nutrition+health+survey+2013-2014+(nhanes)+age+prediction+subset

c) Descripción general del problema

La base de datos proviene del estudio NHANES, el cual recopila información sobre salud y nutrición de la población en Estados Unidos. Este subconjunto fue creado específicamente para abordar un problema de **clasificación**, donde se busca predecir el grupo etario de un individuo (mayor o menor de 65 años) a partir de variables fisiológicas, biomédicas y de estilo de vida.

d) Objetivo del análisis

Construir un modelo estadístico o de machine learning que permita **predecir si un individuo es "senior" (≥65 años) o "no senior" (<65 años)** a partir de variables relacionadas con su salud y comportamiento.

e) Variable objetivo (variable respuesta)

age_group

- Tipo: Categórica nominal
- Categorías:
  - senior (≥65 años)
  - non-senior (<65 años)

f) Diccionario de variables

Variable	Descripción	Tipo
SEQN	Identificador único del individuo	Numérica discreta
age_group	Grupo de edad (variable objetivo)	Categórica nominal
RIDAGEYR	Edad del individuo en años	Numérica continua
RIAGENDR	Género del individuo	Categórica nominal
PAQ605	Actividad física (sí/no)	Categórica nominal
BMXBMI	Índice de masa corporal (BMI)	Numérica continua
LBXGLU	Glucosa en sangre en ayunas	Numérica continua
DIQ010	Diagnóstico de diabetes (sí/no)	Categórica nominal
LBXGLT	Resultado de prueba de tolerancia a glucosa	Numérica continua
LBXIN	Nivel de insulina en sangre	Numérica continua

📌 Nota: Aunque el dataset menciona 7 features principales, algunas variables adicionales aparecen dependiendo del archivo procesado.

g) Número de observaciones

6,287 registros

h) Número de variables

7 variables principales (features) + 1 variable objetivo

i) Posibles hipótesis de estudio

1. **H1:** Los niveles de glucosa en sangre (LBXGLU) son mayores en individuos clasificados como “senior”.
2. **H2:** El índice de masa corporal (BMXBMI) tiene una relación significativa con el grupo de edad.
3. **H3:** Las personas con diagnóstico de diabetes (DIQ010) tienen mayor probabilidad de pertenecer al grupo “senior”.
4. **H4:** La actividad física (PAQ605) está asociada negativamente con ser “senior”.
5. **H5:** Los niveles de insulina (LBXIN) difieren significativamente entre los grupos de edad.