



Profesor: Duván Cataño

Objetivo

Desarrollar un pipeline completo de Machine Learning para un problema de clasificación, aplicando distintos algoritmos supervisados y evaluando su capacidad de generalización mediante validación cruzada y métricas de clasificación.

Comprensión del Problema

1. Definir claramente la variable objetivo.
2. Identificar las clases del problema.
3. Describir el contexto del problema.

Exploración Inicial

1. Analizar la distribución de clases.
2. Identificar posibles problemas de desbalanceo.
3. Analizar:
 - Variables numéricas
 - Variables categóricas
 - Valores faltantes

Preparación de los Datos

1. Separar:
 - Variables predictoras (X)
 - Variable objetivo (y)
2. Dividir los datos:
 - Train (70 %)
 - Test (30 %)
3. Aplicar:
 - Codificación de variables categóricas
 - Escalamiento (cuando aplique)

Importante: Todo el preprocesamiento debe realizarse dentro de un **Pipeline** para evitar fuga de información.

Modelos de Clasificación

Entrenar los siguientes modelos:

1. Regresión Logística
2. Árbol de Clasificación
3. Random Forest Classifier
4. XGBoost Classifier

Validación Cruzada

Aplicar:

- Stratified K-Fold Cross Validation ($k = 5$ o $k = 10$)

Calcular para cada modelo:

- Accuracy
- Precision
- Recall
- F1-Score
- AUC

Reportar resultados como:

$$\text{Métrica} = \mu \pm \sigma$$

Comparación de Modelos

Construir una tabla comparativa con:

- Modelo
- Accuracy (CV)
- Precision (CV)
- Recall (CV)
- F1-Score (CV)
- AUC (CV)

Discusión obligatoria:

- ¿Qué modelo generaliza mejor?
- ¿Cuál presenta mayor estabilidad?
- ¿Cuál métrica es más importante según el problema?

Ajuste de Hiperparámetros

Seleccionar mínimo dos modelos:

- Uno lineal
- Uno basado en árboles

Aplicar:

- RandomizedSearchCV

Comparar:

- Métricas antes y después del ajuste

Evaluación Final

Evaluar el mejor modelo en el conjunto de prueba utilizando:

- Matriz de confusión
- Accuracy
- Precision
- Recall
- F1-Score
- AUC

Interpretación de Resultados

Analizar:

- Falsos positivos
- Falsos negativos
- Riesgos asociados a errores de clasificación

Curva ROC

1. Construir la curva ROC del mejor modelo.
2. Interpretar:
 - Sensibilidad
 - Especificidad
 - Capacidad discriminativa

Importancia de Variables

- Para Regresión Logística:
 - Interpretar coeficientes
- Para modelos de árboles:
 - Analizar importancia de variables

Selección del Modelo Final

Elegir el mejor modelo considerando:

- Desempeño en validación cruzada
- Resultados en test
- Interpretabilidad
- Tipo de error más crítico

Prohibido: elegir únicamente por Accuracy.

Guardado del Modelo

Guardar en `models/` usando :

- `model_classification.joblib`
- `features_classification.joblib`